아티스트 추천 시스템 평가 결과

머신러닝 7조 | 평가 담당 이건희 | 2026년 11월 14일 수정본

동일한 사용자와 후보 아티스트 집합에서 인기도순 추천 비교 기준, 아티스트 기반 협업 필터링, 콘텐츠 기반 필터링을 비교했습니다. 최종 설정의 Precision@10은 협업 필터링 52.15%, 콘텐츠 기반 6.72%였습니다. 콘텐츠 기반은 적중률이 낮았지만 전체 사용자에게 추천한 아티스트의 범위는 더 넓었습니다. 이 보고서는 최종 추천 파일 평가와 설정별 실험, 사용자 사례 및 해석의 한계를 정리합니다.

평가 방법

학습 데이터 224,925행, 평가 데이터 56,727행, 사용자 973명, 아티스트 4,824명을 사용했습니다. 사용자별 청취 아티스트를 무작위로 약 80 대 20으로 분리했으며, 학습에서 이미 들은 아티스트를 제외하고 사용자당 10명을 추천했습니다.

Precision@10은 추천 10명 중 test와 일치한 비율, Recall@10은 해당 사용자의 test 아티스트 중 맞힌 비율입니다. 각 사용자에서 계산한 값을 973명에 대해 산술평균했습니다. 사용자마다 test 크기가 달라 두 지표의 순위가 달라질 수 있습니다.

인기도순 추천은 세 번째 주요 필터링 방식이 아니라 비교 기준입니다. 기존 03_split.ipynb에 있던 방식으로, 학습에서 청취 사용자 수가 많은 아티스트를 우선 추천하되 각 사용자가 이미 들은 아티스트는 제외합니다.

주요 결과

최종 방식 및 설정	Precision@10	Recall@10
인기도순 추천 비교 기준	29.53%	5.46%
아이템 기반 협업 이웃 50명	52.15%	11.35%
콘텐츠 s_log + cosine_learned	6.72%	1.31%

협업 필터링은 추천 10명 중 평균 5.21명이, 콘텐츠 기반은 평균 0.67명이 test와 일치했습니다. 콘텐츠 최종 설정은 청취 가중치 log, 네 특성 log1p 후 표준화, 학습된 특성 가중치의 점수 계산입니다. 두 방식 모두 최종 추천 수는 10명입니다.

최종 설정과 비교 범위

협업 필터링은 train을 다시 사용자별 80 대 20으로 나눈 내부 검증에서 전체·10·20·50명 중 50명을 선택하고, 전체 train으로 유사도를 다시 계산했습니다. 콘텐츠 기반은 전달된 실험의 test 점수를 참고해 최종 설정을 골랐습니다. 두 방식은 최종 평가 데이터가 같지만 설정 선택 절차는 동일하지 않습니다.

콘텐츠 기반 설정별 평가

최종 설정과 기본 설정을 구분합니다. 기본 cosine의 Precision/Recall은 6.44%/1.34%, 기본 cosine_learned는 6.64%/1.27%, 기본 KNN은 4.46%/0.98%입니다. 최종 콘텐츠 설정의 Recall은 1.31%입니다.

ZIP의 9개 CSV를 cosine, cosine_learned, knn으로 나눠 총 27개 조합을 평가했습니다. k3·k5·k20·k50 파일의 두 cosine 방식은 base와 동일하므로, 서로 다른 조합은 19개입니다. 아래 표는 Precision@10이며 모든 Recall 값은 첨부 CSV에 있습니다.

설정	cosine	learned	KNN
base	6.44%	6.64%	4.46%
w_binary	6.45%	6.52%	4.52%
w_plays	6.30%	6.45%	4.07%
s_none	4.08%	4.07%	4.08%
s_log	6.57%	6.72%	4.33%
k3	동일	동일	2.98%
k5	동일	동일	3.63%
k20	동일	동일	5.29%
k50	동일	동일	5.46%

w_binary는 청취 여부, w_plays는 원본 재생 횟수를 가중치로 사용합니다. s_none은 표준화를 생략하고, s_log는 네 음악 특성에 log1p를 적용한 뒤 표준화합니다. k 설정은 KNN 이웃 수만 바꾸며 최종 추천 수는 항상 10명입니다.

관찰한 차이

전체 전달본 중 최고 Precision은 s_log + cosine_learned의 6.72%이고, 최고 Recall은 기본 cosine의 1.34%입니다. KNN은 이웃을 3명에서 50명으로 늘릴수록 성능이 좋아졌지만, 기본 cosine보다 낮았습니다. 표준화를 생략한 설정은 세 방식 모두 Precision 약 4.1%였습니다.

협업 필터링의 이웃 50명은 train 내부 검증에서 선택한 설정입니다. 콘텐츠 설정표는 test에서 관찰한 결과이므로 최고값을 독립적으로 검증된 최적 성능이라고 표현하지 않습니다. learned 코드의 내부 holdout은 특성 가중치 학습에 사용되며, 별도의 설정 선택 검증과는 역할이 다릅니다.

추천 범위와 지표 해석

추천 결과의 적중률 외에 카탈로그 커버리지를 계산했습니다. 전체 973명의 Top 10 추천 목록에 한 번 이상 등장한 고유 아티스트 수를 후보 4,824명으로 나눈 값입니다. 사용자별 다양성이나 실제 만족도를 직접 측정하는 지표는 아닙니다.

방식	고유 아티스트	커버리지	적중 사용자 비율
인기도	68	1.41%	80.68%
협업 필터링	1092	22.64%	95.17%
콘텐츠 기반	1994	41.33%	42.45%

적중 사용자 비율은 10명 중 1명 이상을 맞힌 사용자의 비율입니다. 협업 필터링은 926명, 콘텐츠 기반은 413명, 인기도순 추천 비교 기준은 785명이 한 번 이상 적중했습니다. 콘텐츠 기반은 협업 필터링보다 더 넓은 후보 집합을 추천했지만, 더 좋은 발견 경험이나 더 높은 만족도로 연결됐는지는 확인하지 않았습니다.

Recall이 낮아 보이는 이유

사용자별 test 아티스트 수는 최소 3명, 중앙값 44명, 평균 58.30명, 최대 338명입니다. 100명의 정답을 가진 사용자는 추천 10명을 모두 맞혀도 Recall@10이 10%입니다. 따라서 Recall의 절대값만으로 성능을 판단하지 않고 동일한 사용자·정답 집합에서 방식별 값을 비교합니다. 본 보고서는 사용자별 Recall의 평균이며 총 적중 수를 전체 test 행 수로 나눈 값과는 다릅니다.

결과 차이를 읽는 방법

최종 협업 필터링은 인기도순 추천 비교 기준보다 Precision이 약 22.62퍼센트포인트 높았고, 콘텐츠 기반보다 약 45.43퍼센트포인트 높았습니다. 이 결과는 이번 데이터와 분할에서 청취 이력을 더 잘 복원했다는 의미입니다. 통계적 유의성이나 다른 분할·신규 사용자·미래 청취에 대한 일반화는 별도 검증하지 않았습니다.

동일 사용자에 대한 추천 사례

사례를 성능이 좋은 순서로 고르지 않도록 test 크기의 하위 사분위수 25명과 중앙값 44명에 해당하는 사용자 중 ID가 가장 앞선 사용자를 각각 선택했습니다. 두 사례가 전체 사용자 집단을 대표한다는 뜻은 아닙니다. 아래는 상위 5명만 표시하며, 지표는 추천 10명 전체를 기준으로 계산했습니다. [적중]은 해당 사용자의 test에 포함된 추천입니다.

user_000007

학습 아티스트 100명, test 아티스트 25명. 학습에서 많이 들은 아티스트: brian mcknight (45회), thievery corporation (38회), joe (29회), the o'jays (25회), t.i. (23회)

순위	협업 필터링	콘텐츠 기반
1	snoop dogg	pharrell williams
2	missy elliott	ky-mani marley
3	kelly rowland	garnett silk
4	timbaland	blackstreet
5	jennifer lopez	max romeo

협업 필터링: 10명 중 1명 적중, Precision 10%, Recall 4.00% / 콘텐츠 기반: 10명 중 0명 적중, Precision 0%, Recall 0.00%

user_000063

학습 아티스트 176명, test 아티스트 44명. 학습에서 많이 들은 아티스트: coma (429회), poets of the fall (421회), system of a down (138회), metallica (128회), pid ama porno (114회)

순위	협업 필터링	콘텐츠 기반
1	aerosmith	aerosmith
2	papa roach [적중]	journey
3	disturbed [적중]	månegarm
4	apocalyptica [적중]	hellbillies
5	korn [적중]	hole

협업 필터링: 10명 중 6명 적중, Precision 60%, Recall 13.64% / 콘텐츠 기반: 10명 중 0명 적중, Precision 0%, Recall 0.00%

결과 해석과 재현 범위

성능 차이에 대한 해석

콘텐츠 기반은 아티스트별 평균 음악 특성 9개를 사용합니다. 곡별 스타일 차이와 사용자가 좋아한 특정 곡의 정보가 평균에 압축되며, 언어·문화·인지도 등은 직접 반영되지 않습니다. 반면 협업 필터링은 실제 청취 패턴을 활용합니다. 이러한 차이는 성능 격차에 대한 가능한 설명이며, 원인별 영향을 분리해 검증한 결과는 아닙니다.

test에 없는 새로운 아티스트를 추천하더라도 이번 지표에서는 적중으로 인정되지 않습니다. 따라서 점수는 실제 만족도 전체가 아니라 숨긴 청취 이력의 복원 정도를 나타냅니다. 무작위 분할이므로 미래 시점의 취향 예측 성능으로 일반화하지 않습니다.

검증한 사항

학습·평가 사용자–아티스트 쌍의 중복, 추천 목록의 중복, 기존 청취 아티스트 재추천, 후보 범위 및 추천 순위를 확인했습니다. 모든 전달본의 각 방식은 973명에게 10명씩 추천했습니다. 팀 공통 평가 함수와 별도 사용자별 계산 결과도 일치했습니다.

협업 필터링 기본 및 이웃 50명 결과는 원본 코드 재실행과 정확히 일치했습니다. 콘텐츠 기본 cosine은 재생성 시 작은 수치·동점 순위 차이로 9명의 추천 집합이 달랐고, Precision 차이는 약 0.0103퍼센트포인트였습니다. 본 표는 전달받은 파일을 기준으로 유지했습니다. 나머지 콘텐츠 방식은 전달본을 평가했습니다.

최종 파일과 재현 범위

확인한 main 커밋은 fb5ee0f입니다. 최종 콘텐츠 CSV는 8e01429에서 추가됐고, 기존 s_log 실험의 cosine_learned와 추천 순서 및 점수가 일치합니다. 최종 콘텐츠 지표 6.7215%/1.3130%를 다시 계산해 확인했습니다. 최종 CSV를 기준으로 주요 비교표와 사용자 사례, 추천 커버리지를 갱신했습니다.

평가 스크립트를 수정해 기본 실행은 저장소의 최종 추천 CSV를 직접 읽도록 했습니다. 별도 ZIP 없이 python evaluation/run_evaluation.py로 최종 지표와 커버리지를 재현할 수 있습니다. 과거 콘텐츠 설정 전체를 평가하려면 --content-zip 옵션으로 로컬 ZIP을 지정합니다. 필터링 모델 구현과 기존 추천 파일은 변경하지 않았습니다.

결론과 제한

현재 데이터에서는 아티스트 기반 협업 필터링이 청취 이력 복원에 가장 효과적이었습니다. 콘텐츠 기반의 적중률이 낮은 원인으로 평균 음악 특성의 정보 손실 등을 생각할 수 있지만, 원인별 효과를 분리한 실험은 하지 않았습니다. test를 사용한 콘텐츠 설정 선택, 무작위 분할, 이름 기반 아티스트 결합의 오매칭 가능성을 한계로 명시합니다. 정답에 없는 추천의 실제 가치와 신규 아티스트 추천 성능은 이번 평가로 판단하지 않습니다.

근거 파일: outputs/train.csv, outputs/test.csv, outputs/recs_popular.csv, outputs/recs_memory_cf_selected.csv, content_based_result/content_based_recs.csv 및 evaluation/results/content_all_settings.csv. 저장소 https://github.com/640woo-cloud/music-recommender/tree/main